

IMPLÉMENTATION D'UNE PLATEFORME DE VISIOCONFÉRENCE INTELLIGENTE AVEC TRADUCTION LINGUISTIQUE EN TEMPS RÉEL

NGONO FOUMANE JACQUES FREDY 20R2034
Dr. NZEKON NZEKO'O Armel Jacques
M. ESPERENCE FOPA

17 février 2026

Dédicaces

"Je dédie cette soutenance à tous ceux qui ont contribué à ma réussite et à mon parcours universitaire, en particulier à nos parents respectifs."

Remerciements

Nous tenons à exprimer nos sincères remerciements à toutes les personnes qui ont contribué à la réussite de notre projet et de notre soutenance.

Nous tenons naturellement à adresser nos profonds remerciements :

— À Dr. **NZEKON NZEKO'O ARMEL**, en tant qu'encadreur promoteur et coordinateur du projet **d'Implémentation d'une plateforme de visioconférence intelligente avec traduction linguistique en temps réel**. Nos travaux ont été effectués dans le cadre de ce projet et sous son encadrement à travers des remarques et des suggestions pertinentes.

— À M. **ESPERENCE FOPA**, encadreur professionnel chez **KAIROS**, expert en solutions numériques et en transformation digitale, pour son accompagnement, ses conseils avisés et sa disponibilité tout au long de la réalisation de ce projet.

— À Dr **AMINOU HALIDOU**, chef du département d'informatique de l'Université de Yaoundé I pour les moyens qu'il a mis à notre disposition en vue de notre formation et de l'élaboration de ce travail.

— À tous nos enseignants qui ont su nous transmettre les notions et le savoir qui nous ont permis de mener ce travail à bien, de l'analyse jusqu'à son implémentation.

— Nous disons un grand merci à nos différentes familles pour leur soutien constant et moral, leur encouragement et leur compréhension durant les moments de stress et de doute. Nous pensons ainsi à : **M. NJIEMOUN EMILE**, **Mme MAPON ELISABETH**, **Mme FOGUE MIREILLE IRENE** et tous les autres membres de nos familles.

— À nos camarades de promotion qui ont mis en avant leur esprit collaboratif afin de nous aider dans la réalisation de ce travail.

Nous sommes fiers de ce que nous avons accompli ensemble et nous espérons que notre projet sera bénéfique pour la communauté universitaire et au-delà.

Acknowledgements

We would like to express our sincere gratitude to all the people who contributed to the success of our project and our defense.

We would naturally like to extend our deep thanks :

— To Dr. **NZEKON NZEKO'O ARMEL**, as project supervisor, promoter and coordinator of the project **Implementation of an Intelligent Videoconferencing Platform with Real-Time Linguistic Translation**. Our work was carried out within the framework of this project and under his guidance through valuable remarks and suggestions.

— To Mr. **ESPERENCE FOPA**, professional supervisor at **KAIROS**, expert in digital solutions and digital transformation, for his support, advice and availability throughout the realization of this project.

— To Dr. **AMINOU HALIDOU**, Head of the Computer Science Department at the University of Yaoundé I, for the resources made available to us for our training and for the completion of this work.

— To all our teachers who provided us with the knowledge and skills that enabled us to carry out this work successfully, from analysis to implementation.

— We sincerely thank our families for their constant moral support, encouragement, and understanding during moments of stress and doubt. In particular : **Mr. NJIEMOUN EMILE**, **Mrs. MAPON ELISABETH**, **Mrs. FOGUE MIREILLE IRENE**, and all the other members of our families.

— To our classmates, who demonstrated collaborative spirit to support us in the completion of this work.

We are proud of what we have accomplished together and we hope that our project will be beneficial to the academic community and beyond.

Table des matières

Liste des tableaux

Liste des figures

Définition des sigles et des acronymes

Sigle	Définition
API	Application Programming Interface (interface de programmation)
ASR	Automatic Speech Recognition (reconnaissance automatique de la parole)
AWS	Amazon Web Services (services cloud d'Amazon)
CSS	Cascading Style Sheets (feuilles de style en cascade)
GPU	Graphics Processing Unit (processeur graphique)
HTML	HyperText Markup Language (langage de balisage hypertexte)
HTTP	HyperText Transfer Protocol (protocole de transfert hypertexte)
HTTPS	HyperText Transfer Protocol Secure (HTTP sécurisé)
IA	Intelligence Artificielle
ICE	Interactive Connectivity Establishment (établissement de connectivité interactive)
IDE	Integrated Development Environment (environnement de développement intégré)
JSON	JavaScript Object Notation (format d'échange de données)
JWT	JSON Web Token (jeton d'authentification)
ML	Machine Learning (apprentissage automatique)
NAT	Network Address Translation (traduction d'adresses réseau)
NLP	Natural Language Processing (traitement du langage naturel)
NMT	Neural Machine Translation (traduction automatique neuronale)
REST	Representational State Transfer (style d'architecture pour API)
RTC	Real-Time Communication (communication en temps réel)
RTMP	Real-Time Messaging Protocol (protocole de messagerie en temps réel)
RTP	Real-Time Transport Protocol (protocole de transport en temps réel)
SDP	Session Description Protocol (protocole de description de session)
SGBD	Système de Gestion de Base de Données
SIGL	Systèmes d'Information et Génie Logiciel
SIP	Session Initiation Protocol (protocole d'initiation de session)
STUN	Session Traversal Utilities for NAT (utilitaires de traversée de session pour NAT)
STT	Speech-To-Text (conversion parole en texte)
TIC	Technologies de l'Information et de la Communication
TTS	Text-To-Speech (conversion texte en parole)
TURN	Traversal Using Relays around NAT (traversée utilisant des relais autour du NAT)
UI	User Interface (interface utilisateur)
UML	Unified Modeling Language (langage de modélisation unifié)
UX	User Experience (expérience utilisateur)

Avant-Propos

Cette étude s'inscrit dans le cadre de ma formation en Systèmes d'Information et Génie Logiciel (SIGL) à l'Université de Yaoundé-I. Dans la logique de professionnalisation de cette filière, un stage de fin d'études de six mois est requis afin de mettre en pratique les acquis et de conduire un projet selon un protocole de travail structuré. C'est dans ce contexte que j'ai réalisé mon stage au sein de KAIROS, autour d'un thème centré sur l'**implémentation d'une plateforme de visioconférence intelligente avec traduction linguistique en temps réel**. Le projet mené vise à développer une solution innovante permettant de surmonter les barrières linguistiques lors des communications vidéo, en intégrant des technologies d'intelligence artificielle pour la reconnaissance vocale et la traduction automatique en temps réel. La solution développée, dénommée **ConverseAI**, combine des capacités de visioconférence haute qualité avec un système de traduction simultanée, offrant ainsi une expérience de communication fluide et accessible à l'échelle internationale. Ce rapport présente le contexte, l'architecture et la mise en œuvre de la plateforme, ainsi que les résultats obtenus et les perspectives d'évolution.

Résumé

La communication internationale représente un enjeu majeur dans notre monde globalisé, où les barrières linguistiques limitent souvent la collaboration et les échanges professionnels. Pour répondre à ce besoin, nous avons développé **ConverseAI**, une plateforme de visioconférence intelligente intégrant la traduction linguistique en temps réel. Cette solution adopte une approche modulaire et itérative, combinant un **frontend React** pour l'interface utilisateur interactive, un **backend Node.js/Express** pour la gestion des sessions et l'orchestration des services, et des **services WebRTC** pour la communication audio-vidéo en temps réel. ConverseAI intègre également des **modules d'intelligence artificielle avancés** utilisant des modèles de reconnaissance vocale automatique (ASR) et de traduction neuronale (NMT) pour permettre la traduction simultanée des conversations. La plateforme offre des fonctionnalités avancées telles que la détection automatique de la langue source, la transcription en temps réel, la synthèse vocale de la traduction, et une synchronisation optimale entre l'audio et la vidéo. Cette solution conviviale permet aux utilisateurs de communiquer efficacement sans contraintes linguistiques et ouvre des perspectives d'évolution vers l'intégration de fonctionnalités supplémentaires comme la traduction de documents partagés, l'analyse de sentiment et l'adaptation contextuelle.

Abstract

International communication represents a major challenge in our globalized world, where language barriers often limit collaboration and professional exchanges. To address this need, we developed **ConverseAI**, an intelligent videoconferencing platform integrating real-time linguistic translation. This solution adopts a modular and iterative approach, combining a **React frontend** for the interactive user interface, a **Node.js/Express backend** for session management and service orchestration, and **WebRTC services** for real-time audio-video communication. ConverseAI also integrates **advanced artificial intelligence modules** using automatic speech recognition (ASR) and neural machine translation (NMT) models to enable simultaneous conversation translation. The platform offers advanced features such as automatic source language detection, real-time transcription, text-to-speech synthesis of translations, and optimal audio-video synchronization. This user-friendly solution allows users to communicate effectively without linguistic constraints and opens up prospects for evolution towards the integration of additional features such as shared document translation, sentiment analysis and contextual adaptation.

Introduction Générale

CONTEXTE

Dans le contexte actuel de la mondialisation et de la transformation digitale, la communication internationale représente un défi majeur pour les organisations, les entreprises et les individus. Les échanges professionnels, éducatifs et personnels se déroulent de plus en plus à l'échelle mondiale, nécessitant une communication efficace malgré la diversité linguistique. Selon les données de l'UNESCO, il existe plus de 7 000 langues parlées dans le monde, et les barrières linguistiques constituent l'un des principaux obstacles à la collaboration internationale efficace.

Les plateformes de visioconférence traditionnelles, bien qu'elles permettent de connecter des personnes à distance avec une qualité audio-vidéo satisfaisante, ne résolvent pas le problème fondamental des barrières linguistiques. Dans un contexte où les équipes sont de plus en plus distribuées géographiquement et multiculturelles, le besoin d'outils permettant une communication fluide entre locuteurs de langues différentes devient crucial.

Les avancées récentes en intelligence artificielle, notamment dans les domaines de la reconnaissance automatique de la parole (ASR - Automatic Speech Recognition) et de la traduction automatique neuronale (NMT - Neural Machine Translation), ouvrent de nouvelles perspectives pour résoudre ce défi. Ces technologies permettent désormais d'envisager des systèmes de traduction en temps réel avec une qualité et une latence acceptables pour une utilisation en contexte de visioconférence.

PROBLÉMATIQUE

Comment implémenter une plateforme de visioconférence intelligente qui intègre efficacement la traduction linguistique en temps réel, garantissant

une communication fluide et naturelle entre participants parlant différentes langues, tout en maintenant une qualité de service optimale et une expérience utilisateur intuitive ?

Face à cette problématique, il devient nécessaire de concevoir et de mettre en œuvre une solution intégrée qui combine :

— Les technologies de communication en temps réel (WebRTC) pour la transmission audio-vidéo de haute qualité ;

— L'intelligence artificielle pour la reconnaissance vocale et la traduction automatique ;

— Des mécanismes de synchronisation avancés pour garantir une expérience de communication naturelle ;

— Une architecture modulaire permettant l'évolutivité et l'adaptation à différents contextes d'utilisation.

MÉTHODOLOGIE

Pour atteindre ces objectifs, une méthodologie mixte sera adoptée, combinant une revue de littérature pour identifier les meilleures pratiques et technologies existantes, une phase de conception et de développement logiciel selon une approche agile et itérative, ainsi qu'une phase d'expérimentation et d'évaluation de la solution dans des scénarios réels de communication multilingue.

PLAN DU MÉMOIRE

Ce mémoire est structuré en plusieurs chapitres :

— **Le chapitre 1** présente l'environnement professionnel et le cadre de stage au sein de l'entreprise KAIROS, ainsi que le contexte du projet.

— **Le chapitre 2** présente une revue de la littérature sur les technologies de visio-conférence, la traduction automatique en temps réel, et une analyse des solutions existantes dans ce domaine.

— **Le chapitre 3** décrit l'architecture proposée ainsi que la conception technique de la solution **ConverseAI**.

— **Le chapitre 4** détaille la méthodologie de mise en œuvre et le développement de la plateforme.

— **Le chapitre 5** présente les résultats obtenus et une discussion sur leur portée.

— Enfin, **le chapitre 6** conclut le mémoire en résumant les apports principaux et en proposant des perspectives d'amélioration et de recherche future.

Chapitre 1

Environnement professionnel et cadre de stage

Dans le cadre de ma formation en Master II SIGL (Systèmes d'Information et Génie Logiciel), j'ai été amené à effectuer un stage académique au sein de l'entreprise Kairos, une structure spécialisée dans les solutions numériques et la gestion documentaire. Ce stage, d'une durée de six mois, s'est déroulé principalement au sein du département de développement numérique de l'entreprise.

Cette expérience professionnelle m'a permis d'identifier une problématique concrète liée à la communication multilingue dans les environnements professionnels, donnant naissance à mon projet de fin d'études intitulé : "Implémentation d'une plateforme de visioconférence intelligente avec traduction linguistique en temps réel". Ce chapitre présente l'environnement professionnel dans lequel s'est déroulé mon stage, les activités de l'entreprise d'accueil, ainsi que le contexte spécifique de mon projet.

1. Présentation de l'entreprise Kairos

1.1. Historique et évolution

Kairos est une entreprise camerounaise spécialisée dans les solutions numériques et la gestion documentaire. Fondée avec pour mission de répondre aux besoins croissants des organisations en matière de digitalisation, l'entreprise s'est rapidement imposée comme un acteur de référence dans son domaine d'activité.

L'entreprise a développé une expertise particulière dans l'analyse des besoins organisationnels, la proposition de solutions globales adaptées et le pilotage de leur déploiement, en respectant les contraintes de délais, de qualité et de coûts. Cette approche méthodique et centrée sur le client a contribué à la réputation de Kairos sur le marché camerounais.

1.2. Localisation et implantation

Kairos est stratégiquement implantée au Cameroun, lui permettant de servir efficacement sa clientèle locale tout en ayant une vision régionale. L'entreprise dispose d'installations modernes équipées des technologies nécessaires pour mener à bien ses missions.

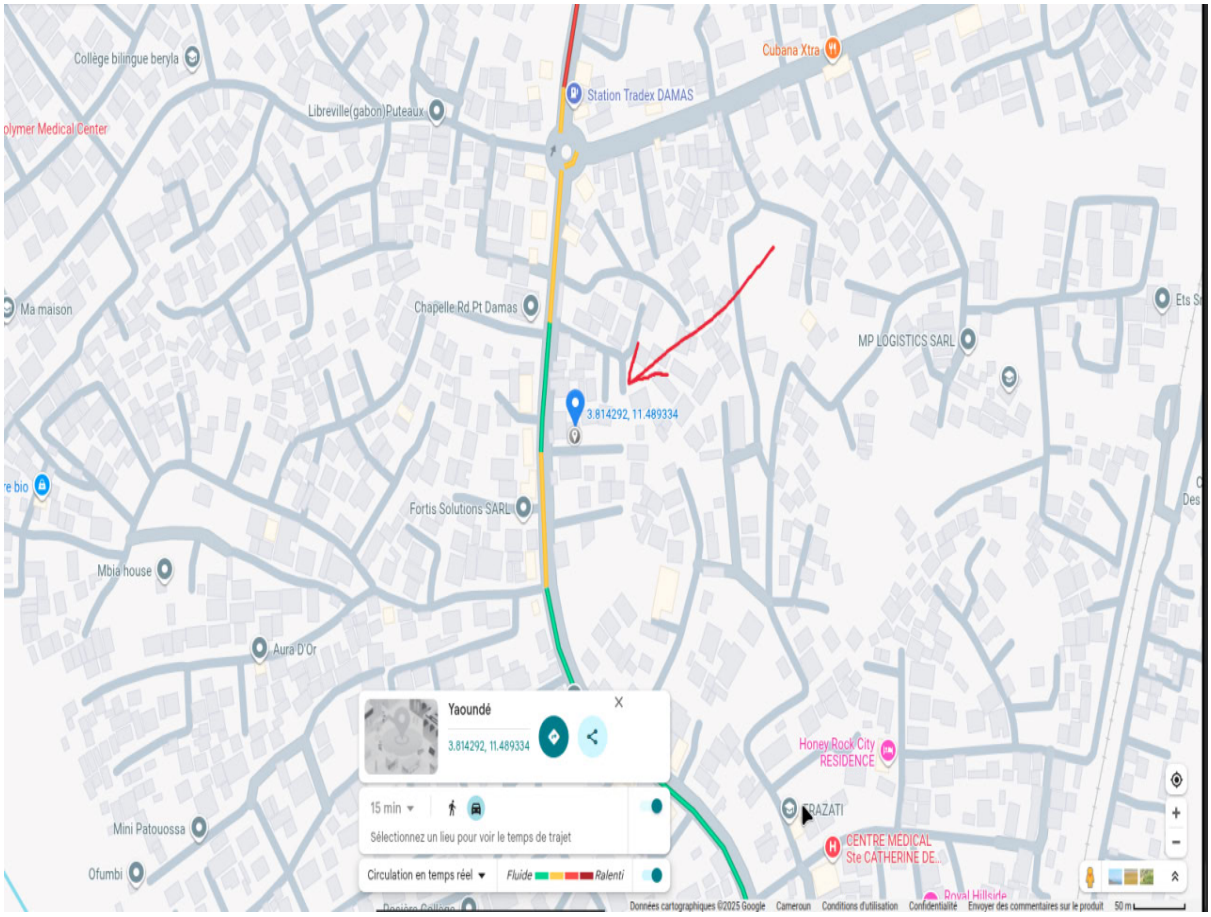


FIGURE 1.1 – Localisation GPS de KAIROS

1.3. Mission et vision

Mission : Kairos analyse les besoins de ses clients, propose des solutions globales adaptées et pilote leur déploiement dans le respect des délais, de la qualité et des coûts.

Vision : Devenir le partenaire de référence des organisations camerounaises et régionales dans leur transformation numérique et l'optimisation de leurs processus.

1.4. Domaines d'activité et services

Kairos propose une gamme complète de services structurés autour de plusieurs axes :

Audit et conseil

L'entreprise offre des prestations d'audit managérial et d'audit documentaire pour aider ses clients à atteindre leurs objectifs. Elle élabore des supports de gouvernance et fournit des conseils pour maintenir la qualité et la sécurité des données et documents.

Veille stratégique

Kairos propose des analyses et des rapports sur les informations et tendances sectorielles, permettant aux clients de prendre des décisions éclairées. L'entreprise met en place des systèmes de veille stratégique performants au sein des organisations.

Développement numérique

L'équipe de développeurs expérimentés accompagne les clients depuis le cahier des charges jusqu'à l'exploitation des solutions. Kairos propose des développements d'applications mobiles sur mesure, la création de sites web d'entreprise ergonomiques et le développement d'applications web innovantes.

Gestion documentaire et archivage

L'entreprise offre des services d'archivage physique et électronique avec des solutions sur mesure pour répondre aux besoins spécifiques de chaque client. Les services incluent également la sauvegarde et la restauration pour garantir la protection des données.

Formation et accompagnement

Kairos propose deux approches : la formation des personnels cibles dans ses métiers et l'accompagnement des équipes pour l'optimisation de leurs pratiques. Les missions incluent le renforcement des parcours professionnels, l'adaptation aux évolutions métier et l'accompagnement des changements organisationnels.

Gestion de projet

L'entreprise accompagne ses clients tout au long du cycle de projet avec une démarche d'accompagnement agile et efficace, gage de réussite pour les projets les plus complexes.

1.5. Organigramme

À la tête de l'entreprise Kairos se trouve une Directrice nommée par le conseil d'administration, choisie pour son expertise dans le domaine de la documentation et de l'archivage, sa vision stratégique et sa capacité à diriger une structure spécialisée. Elle est assistée de cinq collaborateurs directs qui pilotent l'ensemble des activités de l'entreprise.

L'organisation s'articule autour d'une équipe de direction composée de :

— **Directrice** : Direction générale et vision stratégique

— **Attachée de direction** : Support à la direction et coordination

— **Responsable des opérations** : Pilotage des activités opérationnelles

— **Responsable commercial** : Développement commercial et relation client

— **Responsable administratif** : Gestion administrative et financière

— **Coordonnateur des services** : Coordination inter-services

Cette structure permet une organisation efficace autour de trois divisions principales : Kairos Engineering, Kairos Business et Kairos Training Center qui relèvent du Responsable des opérations.

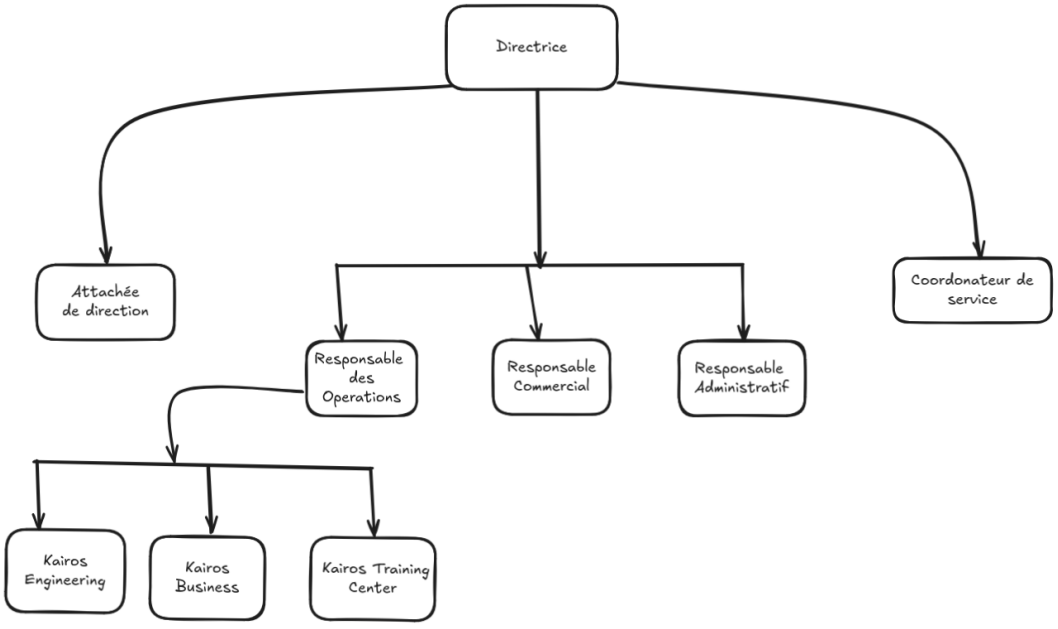


FIGURE 1.2 – Organigramme de l'entreprise KAIROS



FIGURE 1.3 – Logo de l'entreprise KAIROS

2. Déroulement du stage et tâches effectuées

2.1. Accueil et intégration

Mon intégration au sein de Kairos s'est déroulée de manière progressive et structurée. Dès les premiers jours, j'ai été présenté aux différents services et aux membres de l'équipe, permettant une compréhension globale de l'organisation et des enjeux de l'entreprise.

L'accueil chaleureux et professionnel de l'équipe a facilité mon adaptation à l'environnement de travail. Un plan d'intégration avait été préparé, incluant la présentation des outils, des processus internes et des projets en cours. Cette phase d'accueil m'a également permis de mieux cerner les spécificités du département de développement numérique, lieu principal de mon stage.

2.2. Missions et tâches réalisées

Pendant le déroulement de mon stage, j'ai eu à effectuer plusieurs tâches dans le domaine du développement d'applications et de l'intégration de technologies innovantes, me permettant de développer mes compétences et de contribuer concrètement aux projets de l'entreprise :

PÉRIODE	TACHES	DESCRIPTION
Première semaine	Observation et analyse des besoins	Identification des besoins en communication multilingue et des défis techniques associés
Deux premières semaines	Configuration de l'environnement de développement	Préparation et installation des outils et technologies nécessaires au projet de visioconférence
Du 15 avril au 30 juin 2024	Implémentation de la solution	Développement de la plateforme de visioconférence avec traduction en temps réel
Fin de stage	Documentation et transfert	Rédaction de la documentation technique et formation des utilisateurs finaux

TABLE 1.1 – Déroulement détaillé du stage

2.3. Environnement technologique et apprentissages

L'environnement technique de Kairos m'a offert l'opportunité de travailler avec des technologies modernes et des outils professionnels. Le département de développement numérique utilise des technologies variées pour créer des solutions innovantes, ce qui m'a permis de mieux comprendre les enjeux de la communication en temps réel et de l'intelligence artificielle.

Cette expérience m'a également permis d'approfondir mes compétences en développement web full-stack, en intégration d'API d'intelligence artificielle, et en architecture de systèmes distribués. La diversité des projets menés par Kairos m'a donné une vision globale des défis liés à la transformation numérique des organisations.

3. Contexte du projet de fin d'études

3.1. Problématique identifiée

Au cours de mon stage, j'ai observé que les communications internationales de Kairos et de ses clients présentaient des difficultés significatives liées aux barrières linguistiques. L'entreprise collabore régulièrement avec des partenaires et clients francophones, anglophones et d'autres origines linguistiques, ce qui génère des défis de communication.

Les principales difficultés identifiées concernent :

— La nécessité de recourir à des interprètes professionnels lors des réunions multilingues, entraînant des coûts supplémentaires

— Les délais de communication causés par la traduction séquentielle

— La perte d'information et de nuances lors des traductions manuelles

— L'impossibilité de tenir des réunions spontanées avec des interlocuteurs ne parlant pas la même langue

— L'absence de solutions de visioconférence intégrant nativement la traduction en temps réel et adaptées au contexte africain

3.2. Opportunité d'amélioration

L'identification de cette problématique a conduit à la définition de mon projet de fin d'études : développer une plateforme de visioconférence intelligente intégrant la traduction linguistique en temps réel. Cette solution vise à :

— Permettre des communications vidéo fluides entre locuteurs de langues différentes

— Intégrer la reconnaissance vocale automatique pour la transcription en temps réel

— Utiliser la traduction automatique neuronale pour traduire les conversations instantanément

— Offrir une synthèse vocale de qualité pour restituer les traductions

— Garantir une latence minimale pour une expérience de communication naturelle

— Proposer une interface utilisateur intuitive et accessible

3.3. Enjeux stratégiques du projet

Ce projet répond à plusieurs enjeux stratégiques majeurs pour Kairos et ses clients :

Efficacité opérationnelle : Réduction significative des coûts liés à l'interprétation professionnelle et optimisation du temps de communication.

Accessibilité internationale : Facilitation des échanges avec des partenaires et clients internationaux sans contrainte linguistique.

Innovation technologique : Positionnement de Kairos comme acteur innovant dans le domaine des solutions de communication intelligentes.

Inclusion : Démocratisation de l'accès à la communication internationale pour les petites et moyennes entreprises.

Évolutivité : Mise en place d'une architecture flexible capable d'intégrer de nouvelles langues et fonctionnalités.

Bilan du Chapitre

Ce chapitre a permis de présenter l'entreprise KAIROS, le cadre de notre stage et le contexte du projet. L'expertise de KAIROS dans le développement numérique et la gestion documentaire a constitué un environnement propice à l'identification et à la résolution des barrières linguistiques dans la visioconférence.

Chapitre 2

État de l'art et analyse des solutions de visioconférence intelligente

Après avoir présenté l'environnement professionnel et le cadre de stage chez Kairos dans le chapitre précédent, ce chapitre s'attache à explorer l'état de l'art autour des technologies de visioconférence, de la reconnaissance vocale, de la traduction automatique en temps réel, et des solutions existantes intégrant ces capacités.

Il vise à analyser les approches existantes, leurs fonctionnalités, ainsi que leurs forces et limites dans le contexte de la communication multilingue en temps réel.

1. Concepts fondamentaux et définitions

1.1. Évolution de la communication en temps réel

L'histoire de la communication en temps réel s'inscrit dans une longue évolution des technologies de télécommunication et d'informatique.

Dès les années **1970-1980**, les premières expériences de vidéoconférence utilisaient des systèmes propriétaires coûteux nécessitant des infrastructures dédiées. Ces solutions étaient principalement utilisées par les grandes entreprises et les institutions gouvernementales.

Dans les années **1990**, l'avènement d'Internet et des protocoles de communication standardisés a ouvert de nouvelles possibilités. Les protocoles **H.323** et **SIP (Session Initiation Protocol)** ont permis d'établir des standards pour la communication vidéo sur IP. Cependant, ces solutions nécessitaient encore des configurations complexes et des équipements spécialisés.

Le début des années **2000** a marqué l'émergence des solutions de visioconférence grand public, avec des outils comme **Skype** (2003), rendant la communication vidéo accessible au plus grand nombre. Ces plateformes utilisaient des technologies propriétaires pour la transmission audio-vidéo.

Dans les années **2010**, le standard **WebRTC (Web Real-Time Communication)** a révolutionné le domaine en permettant la communication en temps réel directement depuis les navigateurs web, sans nécessiter de plugins ou d'applications dédiées. Cette technologie open source, initiée par Google en 2011, a ouvert la voie à une nouvelle génération d'applications de communication.

De nos jours, les plateformes de visioconférence sont devenues essentielles, particulièrement depuis la pandémie de COVID-19 qui a accéléré l'adoption du travail à distance. L'intégration de l'intelligence artificielle pour améliorer la qualité, la sécurité et l'expérience utilisateur représente la prochaine frontière de l'évolution.

1.2. Technologies de visioconférence modernes

WebRTC : Standard pour la communication en temps réel

WebRTC (Web Real-Time Communication) est une spécification open source qui permet la communication en temps réel (audio, vidéo et données) directement entre navigateurs web et applications mobiles, sans nécessiter de plugins. Les principaux composants de WebRTC sont :

— **MediaStream (getUserMedia)** : API permettant d'accéder aux périphériques multimédia (caméra, microphone)

— **RTCPeerConnection** : Gestion des connexions peer-to-peer pour la transmission audio-vidéo

— **RTCDataChannel** : Canal de données bidirectionnel pour l'échange de données arbitraires

— **STUN/TURN** : Serveurs permettant la traversée des NAT et pare-feu

Protocoles de signalisation

La signalisation dans WebRTC n'est pas standardisée, laissant aux développeurs le choix du protocole. Les approches courantes incluent :

— **WebSocket** : Connexion bidirectionnelle persistante, idéale pour la signalisation en temps réel

— **SIP over WebSocket** : Utilisation du protocole SIP traditionnel sur WebSocket

— **Socket.IO** : Bibliothèque abstraite facilitant la communication temps réel

Codecs audio et vidéo

Les codecs jouent un rôle crucial dans la qualité et la performance de la visioconférence :

Type	**Codec**	**Caractéristiques**
Audio	Opus	Codec audio polyvalent, excellent pour la voix et la musique, adaptatif au débit
Audio	G.711	Codec téléphonique traditionnel, large compatibilité
Vidéo	VP8/VP9	Codecs libres de droits développés par Google
Vidéo	H.264	Standard industriel largement supporté
Vidéo	AV1	Codec nouvelle génération, meilleure compression

TABLE 2.1 – Principaux codecs utilisés en visioconférence

1.3. Technologies de reconnaissance vocale (ASR)

Principes de la reconnaissance automatique de la parole

La **reconnaissance automatique de la parole (ASR - Automatic Speech Recognition)** est le processus de conversion de la parole en texte. Les systèmes ASR modernes utilisent des architectures de réseaux de neurones profonds, notamment :

— **Modèles acoustiques** : Réseaux récurrents (LSTM, GRU) ou Transformers pour modéliser les séquences audio

— **Modèles de langage** : Prédiction des séquences de mots probables

— **Décodeurs** : Algorithmes de recherche (beam search) pour trouver la transcription optimale

Solutions ASR disponibles

Solution	**Avantages**	**Inconvénients**	**Type**
Google Speech-to-Text	Haute précision, nombreuses langues	Coût, dépendance cloud	Cloud
AWS Transcribe	Intégration AWS, streaming	Coût, latence	Cloud
Azure Speech	Personnalisation, nombreuses langues	Complexité	Cloud
Whisper (OpenAI)	Open source, multilingue	Ressources GPU	Local/Cloud
Vosk	Open source, léger, offline	Précision moindre	Local

TABLE 2.2 – Comparaison des solutions ASR

1.4. Technologies de traduction automatique (NMT)

Évolution de la traduction automatique

La traduction automatique a connu plusieurs générations :

1. **Traduction basée sur des règles (RBMT)** : Années 1950-1990, utilisant des dictionnaires et règles grammaticales

2. **Traduction statistique (SMT)** : Années 1990-2010, apprentissage à partir de corpus parallèles
3. **Traduction neuronale (NMT)** : Depuis 2014, utilisant des réseaux de neurones profonds

Architecture des systèmes NMT modernes

Les systèmes de traduction neuronale modernes reposent principalement sur l'architecture **Transformer**, introduite par Vaswani et al. en 2017. Cette architecture utilise des mécanismes d'attention pour capturer les dépendances à long terme dans les séquences.

Les composants clés incluent :

— **Encodeur** : Traitement de la séquence source

— **Décodeur** : Génération de la séquence cible

— **Mécanisme d'attention** : Alignement dynamique entre source et cible

— **Embeddings positionnels** : Encodage de la position des tokens

Solutions NMT disponibles

Solution	**Avantages**	**Inconvénients**	**Type**
Google Translate API	Haute qualité, 100+ langues	Coût, limites d'utilisation	Cloud
DeepL API	Excellente qualité européenne	Langues limitées	Cloud
Azure Translator	Personnalisation, intégration	Complexité	Cloud
LibreTranslate	Open source, auto-hébergé	Qualité variable	Local
Argos Translate	Open source, offline	Paires de langues limitées	Local

TABLE 2.3 – Comparaison des solutions de traduction automatique

1.5. Synthèse vocale (TTS)

Principes de la synthèse vocale

La **synthèse vocale (TTS - Text-to-Speech)** est le processus inverse de l'ASR : conversion du texte en parole. Les systèmes TTS modernes utilisent des modèles neuronaux pour générer une parole naturelle et expressive.

Les architectures populaires incluent :

— **Tacotron/Tacotron 2** : Synthèse end-to-end de spectrogrammes

— **WaveNet/WaveGlow** : Génération de formes d'onde audio

— **FastSpeech** : Synthèse parallèle rapide

— **VITS** : Synthèse variationnelle de bout en bout

2. Analyse des solutions de visioconférence existantes

2.1. Solutions de visioconférence traditionnelles

Zoom

Zoom est devenu la référence des plateformes de visioconférence, particulièrement depuis 2020. La plateforme offre :

— Qualité vidéo HD avec optimisation automatique

— Capacité jusqu'à 1000 participants

— Fonctionnalités de collaboration (partage d'écran, tableau blanc)

— **Zoom Live Transcription** : Transcription en temps réel

— **Zoom Translated Captions** : Sous-titres traduits (fonctionnalité premium récente)

Limitations : La traduction en temps réel reste limitée à certaines langues et nécessite un abonnement premium. L'audio traduit n'est pas disponible nativement.

Microsoft Teams

Microsoft Teams intègre :

— Transcription en temps réel avec identification des locuteurs

— Sous-titres traduits dans plus de 30 langues

— Intégration avec l'écosystème Microsoft 365

— **Teams Premium** : Traduction en direct des réunions

Limitations : Fonctionnalités de traduction complètes réservées aux licences premium. Pas de synthèse vocale de la traduction.

Google Meet

Google Meet propose :

— Sous-titres automatiques en temps réel

— Traduction des sous-titres (fonctionnalité récente)

— Intégration avec Google Workspace

— Réduction du bruit basée sur l'IA

Limitations : Traduction limitée aux sous-titres, pas de traduction audio.

2.2. Solutions spécialisées dans la traduction

Interprefy

Plateforme professionnelle d'interprétation à distance offrant :

— Interprétation simultanée par des professionnels

— Intégration avec les principales plateformes de visioconférence

— Qualité professionnelle garantie

Limitations : Coût élevé (interprètes humains), nécessite une planification préalable.

Wordly

Solution d'IA pour la traduction en temps réel :

— Traduction automatique en temps réel pour événements

— Support de nombreuses langues

— Intégration avec Zoom, Webex

Limitations : Orientée événements, moins adaptée aux réunions quotidiennes.

2.3. Tableau comparatif des solutions

Solution	Transcription	Sous-titres traduits	Audio traduit	Temps réel	Coût
Zoom	Oui	Oui (Premium)	Non	Oui	Élevé
Teams	Oui	Oui (Premium)	Non	Oui	Moyen-Élevé
Google Meet	Oui	Partiel	Non	Oui	Moyen
Interprefy	Oui	Oui	Oui (humain)	Oui	Très élevé
Wordly	Oui	Oui	Oui	Oui	Élevé
ConverseAI	Oui	Oui	Oui (IA)	Oui	Accessible

TABLE 2.4 – Comparaison des solutions de visioconférence avec traduction

3. Défis techniques de la traduction en temps réel

3.1. Latence et synchronisation

Le défi majeur de la traduction en temps réel est la gestion de la latence. La chaîne de traitement comprend plusieurs étapes, chacune ajoutant un délai :

1. **Capture audio** : 20-50 ms
2. **Reconnaissance vocale (ASR)** : 200-500 ms
3. **Traduction (NMT)** : 100-300 ms
4. **Synthèse vocale (TTS)** : 100-200 ms
5. **Transmission réseau** : Variable

La latence totale peut atteindre 1-2 secondes, ce qui peut impacter l'expérience de conversation naturelle.

3.2. Qualité de la reconnaissance vocale

La précision de l'ASR dépend de plusieurs facteurs :

— Qualité du microphone et de l'environnement audio

— Accent et prononciation du locuteur

— Vocabulaire spécialisé ou technique

— Langues à faibles ressources

3.3. Qualité de la traduction

Les défis de la traduction automatique incluent :

— Ambiguïtés linguistiques et contextuelles

— Expressions idiomatiques et culturelles

— Terminologie spécialisée

— Paires de langues peu représentées

3.4. Synchronisation audio-vidéo

Maintenir la synchronisation entre l'image du locuteur et l'audio traduit est crucial pour une expérience naturelle. Cela nécessite des mécanismes de buffering et de synchronisation sophistiqués.

4. Synthèse et positionnement de notre solution

L'analyse de l'état de l'art révèle plusieurs constats :

1. Les solutions de visioconférence traditionnelles (Zoom, Teams, Meet) intègrent progressivement des fonctionnalités de transcription et de traduction, mais celles-ci restent limitées (sous-titres uniquement, pas d'audio traduit)
2. Les solutions professionnelles de traduction (Interprefy) offrent une qualité optimale mais à des coûts prohibitifs pour une utilisation quotidienne
3. Les solutions IA émergentes (Wordly) sont principalement orientées événements et moins adaptées aux réunions courantes
4. Aucune solution ne propose actuellement une intégration complète et accessible de la traduction audio en temps réel pour les communications quotidiennes

Notre solution **ConverseAI** se positionne comme une plateforme de visioconférence intelligente offrant :

— Une intégration complète du pipeline ASR $\rightarrow$ NMT $\rightarrow$ TTS

— Une traduction audio en temps réel, pas seulement des sous-titres

— Une architecture modulaire permettant l'adaptation et l'évolution

— Un coût accessible pour une utilisation quotidienne

— Une interface intuitive ne nécessitant pas d'expertise technique

— Un focus sur les langues pertinentes pour le contexte africain et international

Le chapitre suivant présentera l'architecture technique et la conception détaillée de la plateforme ConverseAI.

Bilan du Chapitre

L'exploration de l'état de l'art a mis en évidence le potentiel des technologies WebRTC et de l'intelligence artificielle pour la visioconférence multilingue. Bien que des solutions commerciales existent, elles présentent des limites en termes de traduction audio complète et d'accessibilité, justifiant ainsi le développement de notre solution ConverseAI.